R语言学习 - 热图简化

原创: 陈同 生信宝典 2017-07-05

虽然有点丑, 但一步就出来了。

热图绘制 - pheatmap

绘制热图除了使用 ggplot2 , 还可以有其它的包或函数, 比如 pheatmap::pheatmap (pheatmap包中的pheatmap函数)、 gplots::heatmap.2 等。

相比于 ggp1ot2 作heatmap, pheatmap 会更为简单一些,一个函数设置不同的参数,可以完成行列聚类、行列注释、Z-score计算、颜色自定义等。那我们来看看效果怎样。


```
data_ori <- "Grp_1;Grp_2;Grp_3;Grp_4;Grp_5
a;6.6;20.9;100.1;600.0;5.2
b;20.8;99.8;700.0;3.7;19.2
c;100.0;800.0;6.2;21.4;98.6
d;900;3.3;20.3;101.1;10000"

data <- read.table(text=data_ori, header=T, row.names=1, sep=";", quote="")

   Grp_1 Grp_2 Grp_3 Grp_4 Grp_5
a   6.6  20.9 100.1 600.0  5.2
b  20.8  99.8 700.0  3.7  19.2
c  100.0 800.0  6.2 21.4  98.6
d  900.0  3.3  20.3 101.1 10000.0

pheatmap::pheatmap(data, filename="pheatmap_1.pdf")</pre>
```


第1页 共18页 2019/10/25 下午1:36



在 heatmap美化 篇提到的数据前期处理方式,都可以用于 pheatmap 的画图。此外 Z-score 计算在 pheatmap 中只要一个参数就可以实现。

pheatmap::pheatmap(data, scale="row", filename="pheatmap_1.pdf")


第2页 共18页 2019/10/25 下午1:36



有时可能不需要行或列的聚类, 原始展示就可以了。

pheatmap::pheatmap(data, scale="row", cluster_rows=FALSE, cluster_cols=FALSE,

第3页 共18页 2019/10/25 下午1:36



给矩阵 (data)中行和列不同的分组注释。假如有两个文件,第一个文件为行注释,其第一列与矩阵中的第一列内容相同 (顺序没有关系),其它列为第一列的不同的标记,如下面示例中(假设行为基因,列为样品)的2,3列对应基因的不同类型 (TF or enzyme)和不同分组。第二个文件为列注释,其第一列与矩阵中第一行内容相同,其它列则为样品的注释。

row_anno = data.frame(type=c("TF","Enzyme","Enzyme","TF"), class=c("clul","cluerow_anno

type class

a TF c1u1


b Enzyme clul

c Enzyme clu2

第4页 共18页 2019/10/25 下午1:36

```
TF c1u2
d
col_anno = data.frame(grp=c("A","A","A","B","B"), size=1:5, row.names=colnames
co1_anno
      grp size
Grp_1
      A
            1
Grp_2
      A
Grp_3
      A
           3
Grp_4 B
           4
Grp_5 B 5
pheatmap::pheatmap(data, scale="row",
cluster_rows=FALSE,
annotation_col=col_anno,
annotation_row=row_anno,
filename="pheatmap_1.pdf")
```


第5页 共18页 2019/10/25 下午1:36



自定义下颜色吧。

```
# <bis> values larger than 1 will give more color for high end.
# Values between 0-1 will give more color for low end.
pheatmap::pheatmap(data, scale="row",
cluster_rows=FALSE,
annotation_col=col_anno,
annotation_row=row_anno,
color=colorRampPalette(c('green','yellow','red'), bias=1)(50),
filename="pheatmap_l.pdf")
```

第6页 共18页 2019/10/25 下午1:36



heatmap.2 的使用就不介绍了, 跟 pheatmap 有些类似, 而且也有不少教程。

不改脚本的热图绘制

绘图时通常会碰到两个头疼的问题:

- 1. 需要画很多的图,唯一的不同就是输出文件,其它都不需要修改。如果用 R脚本,需要反复替换文件名,繁琐又容易出错。
- 2. 每次绘图都需要不断的调整参数,时间久了不用,就忘记参数放哪了;或 者调整次数过多,有了很多版本,最后不知道用哪个了。

为了简化绘图、维持脚本的一致, 我用 bash 对 R 做了一个封装, 然后就可以通过

第7页 共18页 2019/10/25 下午1:36

修改命令好参数绘制不同的图了。

先看一看怎么使用

首先把测试数据存储到文件中方便调用。数据矩阵存储在 heatmap_data.x1s 文件中; 行注释存储在 heatmap_row_anno.x1s 文件中; 列注释存储在 heatmap_col_anno.x1s 文件中。

tab键分割,每列不加引号
write.table(data, file="heatmap_data.xls", sep="\t", row.names=T, col.names=T
如果看着第一行少了ID列不爽,可以填补下
system("sed -i '1 s/^/ID\t/' heatmap_data.xls")
write.table(row_anno, file="heatmap_row_anno.xls", sep="\t", row.names=T, col
write.table(col_anno, file="heatmap_col_anno.xls", sep="\t", row.names=T, col

然后用程序 sp pheatmap.sh 绘图。

-f: 指定输入的矩阵文件

-d: 指定是否计算Z-score, <none> (否), <row> (按行算), <co1> (按列算)


-P: 行注释文件

-Q: 列注释文件

ct@ehbio:~/\$ sp_pheatmap.sh -f heatmap_data.x1s -d row -P heatmap_row_anno.x1s

一个回车就得到了下面的图

第8页 共18页



字有点小,是因为图太大了,把图的宽和高缩小下试试。

-f: 指定输入的矩阵文件

-d: 指定是否计算Z-score, <none> (否), <row> (按行算), <co1> (按列算)

-P: 行注释文件


-Q: 列注释文件

-u: 设置宽度, 单位是inch

-v: 设置高度, 单位是inch

 $\verb|ct@ehbio:|^{\$} sp_pheatmap.sh -f heatmap_data.x1s -d row -P heatmap_row_anno.x1s -d row -$

第9页 共18页 2019/10/25 下午1:36




横轴的标记水平放置

第10页 共18页 2019/10/25 下午1:36

- # -A: 0, X轴标签选择0度
- # -C: 自定义颜色, 注意引号的使用, 最外层引号与内层引号不同, 引号之间无交叉
- #-T: 指定给定的颜色的类型: 如果给的是vector (如下面的例子),则-T需要指定为vector
- # -t: 指定图形的题目,注意引号的使用; 参数中包含空格或特殊字符等都要用引号引起来 ct@ehbio:~/\$ sp_pheatmap.sh -f heatmap_data.x1s -d row -P heatmap_row_anno.x1s

第11页 共18页 2019/10/25 下午1:36



sp_pheatmap.sh 的参数还有一些,可以完成前面讲述过的所有热图的绘制,具体

第12页 共18页 2019/10/25 下午1:36

如下:

T4 1

T4 2

T4

T4

----Column annorarion file -----

```
***CREATED BY Chen Tong (chentong biology@163.com)***
----Matrix file-----
      TO 1
           T0 2 T0 3 T4 1 T4 2
TR19267 c0 g1 CYP703A2 1.431
                                    1.309 1.247 0.485
                             0.77
TR19612 cl g3 CYP707A1
                      0.72
                            0.161
                                    0.301
                                             2.457
                                                    2.794
TR60337 c4 g9 CYP707A1 0.056 0.09 0.038 7.643
                                                    15.379
TR19612 c0 g1 CYP707A3 2.011
                             0.689 1.29 0 0
TR35761 c0 g1 CYP707A4
                     1.946 1.575 1.892 1.019 0.999
TR58054 c0 g2 CYP707A4 12.338 10.016 9.387
                                              0.782 0.563
TR14082 | c7 g4 | CYP707A4
                     10.505
                              8.709
                                      7.212
                                              4.395
                                                     6.103
TR60509 c0 g1 CYP707A7
                     3.527
                             3.348 2.128
                                             3.257
                                                     2.338
TR26914 c0 g1 CYP710A1
                             1.54 0.998 0.255
                     1.899
                                                    0.427
----Matrix file-----
----Row annorarion file -----
----1. At least two columns-----
----2. The first column should be the same as the first column in
       matrix (order does not matter)-----
Name
      C1an
             Family
TR19267 | c0_g1 | CYP703A2
                      CYP71
                              CYP703
TR19612 | c1_g3 | CYP707A1
                      CYP85
                             CYP707
TR60337 c4 g9 CYP707A1
                      CYP85
                             CYP707
TR19612 c0_g1 CYP707A3
                      CYP85
                            CYP707
TR35761 c0 g1 CYP707A4
                      CYP85
                             CYP707
TR58054 | c0 g2 | CYP707A4
                      CYP85
                             CYP707
TR14082 | c7_g4 | CYP707A4
                      CYP85
                             CYP707
TR60509 c0 g1 CYP707A7
                      CYP85
                              CYP707
TR26914 | c0_g1 | CYP710A1
                      CYP710
                              CYP710
----Row annorarion file -----
----Column annorarion file -----
----1. At least two columns-----
----2. The first column should be the same as the first row in
-----matrix (order does not matter)-----
      Sample
Name
TO_1
      T0
T0 2
      T0
T0_3
      TO
```

第13页 共18页 2019/10/25 下午1:36

```
Usage:
sp pheatmap.sh options
Function:
This script is used to do heatmap using package pheatmap.
The parameters for logical variable are either TRUE or FALSE.
OPTIONS:
    -f
          Data file (with header line, the first column is the
         rowname, tab seperated. Colnames must be unique unless you
        know what you are doing.) [NECESSARY]
          Title of picture [Default empty title]
    -†.
        ["Heatmap of gene expression profile"]
         Display xtics. [Default TRUE]
    -a
          Rotation angle for x-axis value (anti clockwise)
    -A
        Default 90
         Display ytics. [Default TRUE]
    -h
         Hieratical cluster for columns.
       Default FALSE, accept TRUE
          Hieratical cluster for rows.
    -R
       Default TRUE, accept FALSE
         Clustering method, Default "complete".
        Accept "ward.D", "ward.D2", "single", "average" (=UPGMA),
        "mcquitty" (=WPGMA), "median" (=WPGMC) or "centroid" (=UPGMC)
    -C
         Color vector.
        Default pheatmap default.
        Accept a vector containing multiple colors such as
        <'c("white", "blue")'> will be transferred
        to <colorRampPalette(c("white", "blue"), bias=1)(30)>
        or an R function
        <colorRampPalette(rev(brewer.pal(n=7, name="RdY1Bu")))(100)>
        generating a list of colors.
    -T
         Color type, a vetcor which will be transferred as described in <-C>
           a raw vector [direct vector] or a function [function (default)]
          A positive number. Default 1. Values larger than 1 will give more co
    -B
           for high end. Values between 0-1 will give more color for low end.
          Clustering distance method for rows.
    -D
        Default 'correlation', accept 'euclidean',
        "manhattan", "maximum", "canberra", "binary", "minkowski".
    - T
         Clustering distance method for cols.
        Default 'correlation', accept 'euclidean',
        "manhattan", "maximum", "canberra", "binary", "minkowski".
```

第14页 共18页 2019/10/25 下午1:36

```
First get log-value, then do other analysis.
   Accept an R function log2 or log10.
   [Default FALSE]
     Scale the data or not for clustering and visualization.
-d
   [Default 'none' means no scale, accept 'row', 'column' to
   scale by row or column.
     The maximum value you want to keep, any number larger will1
   be taken as this given maximum value.
    [Default Inf, Optional]
     The smallest value you want to keep, any number smaller will
   be taken as this given minimum value.
    [Default -Inf, Optional]
-k
     Aggregate the rows using kmeans clustering.
   This is advisable if number of rows is so big that R cannot
   handle their hierarchical clustering anymore, roughly more than 1000.
    Instead of showing all the rows separately one can cluster the
   rows in advance and show only the cluster centers. The number
   of clusters can be tuned here.
    [Default 'NA' which means no
   cluster, other positive interger is accepted for executing
   kmeans cluster, also the parameter represents the number of
   expected clusters.
     A file to specify row-annotation with format described above.
   [Default NA]
-()
     A file to specify col-annotation with format described above.
    [Default NA]
     The width of output picture. [Default 20]
-u
     The height of output picture. [Default 20]
-v
     The type of output figures. Default pdf, accept
-E
   eps/ps, tex (pictex), png, jpeg, tiff, bmp, svg and wmf)]
     The resolution of output picture. [Default 300 ppi]
-F
     Font size [Default 14]
     Preprocess data matrix to avoid 'STDERR 0 in cor(t(mat))'.
   Lowercase .
   [Defau1t TRUE]
     Execute script (Default) or just output the script.
```

your first time run s-plot.[Default FALSE]

Install the required packages. Normmaly should be TRUE if this is

sp_pheatmap.sh 是我写作的绘图工具 s-plot 的一个功能, s-plot 可以绘制的图的类型还有一些,列举如下;在后面的教程中,会一一提起。

Usage:

[Default TRUE]

第15页 共18页 2019/10/25 下午1:36

Heatmap
s-plot heatmapS

```
s-plot options
Function:
This software is designed to simply the process of plotting and help
researchers focus more on data rather than technology.
Currently, the following types of plot are supported.
#### Bars
s-plot barPlot
s-plot horizontalBar
s-plot multiBar
s-plot colorBar
#### Lines
s-plot lines
#### Dots
s-plot pca
s-plot scatterplot
s-plot scatterplot3d
s-plot scatterplot2
s-plot scatterplotColor
s-plot scatterplotContour
s-plot scatterplotLotsData
s-plot scatterplotMatrix
s-plot scatterplotDoubleVariable
s-plot contourPlot
s-plot density2d
#### Distribution
s-plot areaplot
s-plot boxplot
s-plot densityPlot
s-plot densityHistPlot
s-plot histogram
#### Cluster
s-plot hcluster_gg (latest)
s-plot hcluster
s-plot hclust (depleted)
```

第16页 共18页 2019/10/25 下午1:36

s-plot heatmapM

s-plot heatmap.2

s-plot pheatmap

s-plot pretteyHeatmap # obseleted

s-plot prettyHeatmap

Others

s-plot volcano

s-plot vennDiagram

s-plot upsetView

为了推广,也为了激起大家的热情,如果想要 sp_pheatmap.sh 脚本的,还需要劳烦大家动动手,转发此文章到朋友圈,并留言索取。



学习 宏基因组 关照此公众号。

第17页 共18页



阅读原文

第18页 共18页 2019/10/25 下午1:36